

研究主線結構圖

第一層：caller-first

GQ / QUAL / FILTER 為主規則，穩定成立、跨 dataset 最一致

第二層：methylation-support

Quality_Score / PairwiseMedianDist / agreement_positive 補強排序

第三層：haplotype / SNV / 甲基共分析

驗證 label 合理性、subclone 研究、annotation / QC / diagnostics

四象限資料

HKU_5kHz
paired

DORADO
paired

HKU_5kHz
TO

DORADO
TO

InterSubMod AI 自動化 F1 研究主線

用 AI / Agent 自動化推進 InterSubMod F1-score 驗證

AI-assisted InterSubMod F1-score Optimization and Validation

最穩定結論：caller-first 主規則 → 甲基 support/annotation → haplotype 共分析三層分工。

16 頁技術深度版

研究內部技術深度驗證版

draft

報告整理時間 | 2026-03-12

報告人 | 廖子游

所有細節推論與絕對路徑均嵌入 speaker notes。

報告總覽

Agenda

先講研究問題與主結論，再依序處理 paired、TO、Pool B、annotation 與 mixed sample。

0
1

主結論與 AI 自動化

第 3-6 頁

0
2

樣本策略與 paired/TO

第 7-9 頁

0
3

前段 TP rescue：Pool B FN

第 10 頁

0
4

特徵分工與 annotation

第 11-13 頁

0
5

mixed sample 與下一步

第 14-15 頁

0
6

附錄與重生路徑

第 16 頁

高層導讀：本 deck 的重點不是再推一條新規則，而是把 caller、甲基 support、annotation 與 mixed 假說放到正確層次。

破題結論

Opening Thesis

目前最穩定的結論是 caller-first ； 甲基訊號有價值，但還沒有穩定升級成第一層主規則。

最穩定結論： caller-first 主規則 → methylation-support / annotation → haplotype / SNV / 甲基共分析。

Stable structure: caller-first, then methylation support/annotation, then multi-omics co-analysis.

三句一定要先講清楚

caller-first 是目前最穩定的主規則
(GQ、QUAL、FILTER)

甲基特徵有用，但多數應定位為 support / annotation ，尚未穩定超過最佳 caller-only

5kHz 上成立的規則，不能直接假設在 DORADO 同樣成立

第一層： caller-first

Layer 1: Caller-first

GQ / QUAL / FILTER 為主規則，穩定成立、跨 dataset 最一致

第二層： methylation-support

Layer 2: Methylation Support

Quality_Score / PairwiseMedianDist / agreement_positive 補強排序

第三層： haplotype / SNV / 甲基共分析

Layer 3: Multi-omics Co-analysis

驗證 label 合理性、subclone 研究、annotation / QC / diagnostics

這份簡報之後的所有數據頁，都只是把這個結論拆開驗證，而不是推翻它。

為什麼最近改用 AI / Agent 自動化

Why AI-assisted Automation

研究策略已從手動觀察零散位點，轉成可持續重跑、回寫、追版本的研究循環。

Before

手動觀察少數位點

手動試少量規則

手動記錄零散結論

每次重開對話從頭理解

After

AI 自動讀 docs/knowledge，對齊主線與已驗證結論

AI 自動跑 feature sweep / candidate rescue / 參數組合

每輪實驗產生結構化 .md 報告，自動寫入索引

AI 沿著已驗證主軸繼續推進，不重複踩舊方向

研究價值：每個方向都留下可複查的數據與結論；快速識別哪些規則只在單一樣本成立；不穩定特徵先降階為 annotation，不過早硬接主規則

這輪刻意只限制 AI 先做兩類問題

Two Restricted Research Questions

前段救 TP 與後段刪 FP 必須拆開談，因為兩者母體不同。

問題 A：後段刪 FP

FP Triage (Post-caller)

caller / LongPhase / InterSubMod 最終輸出後，能否再刪 FP 而不刪太多 TP

典型研究子集

5kHz paired
5kHz TO
DORADO paired
DORADO TO

母體：caller 已保留的 call set

問題 B：前段救 TP

TP Rescue (Pre-caller)

一開始被 caller 移掉的 truth-like 位點，能否透過放寬條件配合甲基結果救回

典型研究子集

caller_lost_tp
Pool B FN
candidate-specific rescue


母體：caller 已刷掉的 non-PASS 或 lost TP 候選

兩類問題母體不同，不能混成同一套規則。 AlleleDelta 在兩種母體中方向可能相反。

自動化研究流程與 tagged BAM 的角色

Workflow

這條流程真正的核心，是把報告、資料、LongPhase、InterSubMod 與回寫索引接成一條可重跑鏈。



tagged BAM 為什麼重要

InterSubMod 需要 haplotagged BAM。

沒有 tagged BAM，就不能做真正的 HP / label-first 驗證。

因此 paired 用 LongPhase-S，TO 用 LongPhase-TO。

先純樣本，再 mixed

樣本策略：為什麼先做 5kHz，再用 DORADO 驗證

Sample Strategy

5kHz 提供規則壓力測試； DORADO 負責檢查這些規則是否只是平台特異性。

HCC1395_HKU_5kHz (主)

Primary: 5kHz

較 noisy，FP 較多，適合找刪 FP / 救 TP 規則
big8_disk 已有完整 paired / TO tagged BAM
主實驗壓力測試場景

HCC1395_DORADO (輔)

Cross-validation: DORADO


同樣本、不同定序流程，乾淨基準
用來檢查規則是否只是平台特異性
candidate-window subset tagged BAM

big8_disk 空間有限，其他樣本後續移至 big7_disk。5kHz paired / TO 完整 tagged BAM 已驗證； DORADO TO 為 candidate-window subset。

paired 主結果

Paired Results

paired 問題目前最合理的口徑是：caller 與 LongPhase 已做掉主要改善，InterSubMod 在 5kHz 上再做少量 precision 精修。



圖表解讀：兩個 paired dataset 都先經過 ClairS → LongPhase-S → InterSubMod，比較 F1 變化與增益來源。

5kHz paired

ClairS 0.8443 → LongPhase-S 0.8522 → InterSubMod 0.8532
增益來源：FP 627 → 544，額外少 83 個 FP
TP 並未大量救回，反而少 2 個

DORADO paired


ClairS 0.8565 → LongPhase-S 0.8592 → InterSubMod 0.8590
InterSubMod 與 LongPhase-S 幾乎持平略負
代表規則方向不可直接宣稱跨平台可攜

重點：paired 的正式口徑是『precision 精修』，不是『大量 TP rescue』。

tumor-only 主結果

Tumor-only Results

TO 下 caller-first 與甲基 support 都成立，但在固定 caller gate 後，甲基尚未穩定超過 caller-only。



HCC1395 5kHz TO

caller-first : gq>=10 , 499 TP / 119 FP , $\Delta F1 +0.006943$

support 1 : Pairwise>=0.20 , 300 TP / 68 FP , $\Delta F1 +0.004219$

support 2 : agreement+ , 148 TP / 25 FP , $\Delta F1 +0.002163$

caller-first 與 **甲基 support** 都有單獨正效果，但 **甲基** 仍未超過最佳 **caller-only**

HCC1395 DORADO TO

caller-first : gq>=10 , 40 TP / 11 FP , $\Delta F1 +0.000540$

support 1 : Quality>=60 , 208 TP / 77 FP , $\Delta F1 +0.002620$

support 2 : Pairwise<=0.20 , 173 TP / 60 FP , $\Delta F1 +0.002217$

DORADO 的 **Pairwise** 方向與 **5kHz** 相反 (**<=0.20**)，支持 **dataset-dependence**

圖表解讀：左圖為 5kHz TO，右圖為 DORADO TO；Y 軸皆為相對 baseline 的 $\Delta F1$ 。

Pool B FN：前段 TP rescue 問題的正式收尾

Pool B FN Closeout

Pool B 再次證明 caller-side rescue 空間存在，但甲基只提供弱補強，沒有翻盤。

Pool B FN

840

個 non-PASS 但 truth set 包含的位點

這是一條『前段救 TP』問題，
不能和 kept-set artifact triage 混寫。

no_varcluster

TP 428 | FP 390 | $\Delta F1$ +0.003391

caller rescue 空間存在

no_varcluster + gq15

TP 115 | FP 45 | precision 71.9% | $\Delta F1$ 較小

最高 precision

gq15 + allele_delta_low

TP 431 | FP 473 | $\Delta F1$ +0.002702

甲基只提供弱補強

Pool B 要帶出的口徑

Pool B 再次證明 caller-side rescue 空間存在
甲基只提供弱補強，沒有超過 caller-only 最佳規則

AlleleDelta 在 Pool B 與 TO kept-set 方向不同，不可混成全域規則

關鍵：AlleleDelta 在 Pool B 與 kept-set / artifact triage 的方向不同。

現在最重要的特徵與分工

Feature Roles

有用的特徵不一定能升級成主規則；有些特徵最合理的位置，是 support、annotation 或 artifact 旁路。

GQ 定位：caller-first 限制：不可直接解讀成 caller 應全面放寬 ✓ 已是主規則	agreement_positive 定位：5kHz TO 較有價值 限制：不可當所有 dataset 主 rescue ○ 保留為 support
QUAL>=10 or GQ>=20 定位：5kHz TO caller gate 限制：不可寫成所有 TO 的通則 ○ dataset-specific	Strong / Subclone label 定位：部分情境可解讀 限制：FP 也可能很高 ✗ 不可升級
Quality_Score 定位：兩個 TO 都有正訊號 限制：不可直接 hard keep ↑ 可升 annotation	low VAF + high AD + low CV 定位：5kHz 刪 FP 有用 限制：不可當 TP rescue 主規則 ○ 保留 artifact 旁路
PairwiseMedianDist 定位：5kHz 偏高；DORADO 偏低 限制：不可全域固定方向 ↑ 可升 dataset-aware annotation	
這張表的重點不是『誰有用』，而是『每個訊號現在應該被擺在哪一層』。	

annotation / 三層架構：現在最合理的整合方式

Annotation Architecture

這個三層架構不是抽象口號，而是目前最適合繼續研究與輸出的方法學切分。

第一層：caller-first

GQ / QUAL / FILTER 為主規則，穩定成立、跨 dataset 最一致

第二層：methylation-support

Quality_Score /
PairwiseMedianDist / agreement_
positive 補強排序

第三層：haplotype / SNV / 甲基共分析

驗證 label 合理性、subclone
研究、annotation / QC / diagnostics

GQ / QUAL / FILTER

caller-first 主規則

第一層先避免漏掉太多 TP

Quality_Score

support annotation

在 TO 兩個資料集都不是負訊號

PairwiseMedianDist

dataset-aware annotation

方向依 dataset 而變，不可全域化

hp_assign_rate

phase / QC annotation

反映相位完整度，不應直接拿來 truth keep

現階段最合理的策略是：第一層盡量避免漏掉太多 TP，第二層避免帶回太多 FP，第三層負責驗證與可解釋性。

四象限可比性與解讀邊界

Comparability Limits

5kHz 與 DORADO 的差異可用來做方向判讀，但 dataset-dependence 仍需保守解讀。

為什麼 5kHz / DORADO 會分化

5kHz 初始 FP 較多（ClairS FP=1,430），甲基特徵更有機會顯現正增益

DORADO baseline 已較乾淨（ClairS FP=588），規則帶來的增益縮小

PairwiseMedianDist 在兩個 dataset 方向相反，顯示 dataset-dependence

可能的解釋：定序流程特異性 + noisy sample 對甲基特徵更敏感

合理推論：**noisy sample** 對甲基特徵更敏感，但這還不是已證明因果。

四象限比較時不能忘記的限制

paired candidate-specific coverage 只有 8%~20%，TO 才到 71%~100%。

5kHz TO snapshot 來自 full tagged BAM；DORADO TO 來自 subset tagged BAM。

PairwiseMedianDist 在 5kHz TO 偏高、在 DORADO TO 偏低，因此只能做 dataset-aware support annotation。

甲基 rescue 在 paired 目前沒看到穩定正向，不代表 paired 一定沒有甲基價值。

正確口徑：目前規則在 5kHz 有效，尚未穩定跨平台成立。

mixed sample 的目前位置：假說，不是定論

Mixed Sample Hypothesis

mixed sample 目前只能講到初步觀察與合理推論，正確策略是先把純樣本做完，再回來做校正驗證。

當前觀察

tumor < normal < mixed

PairwiseMedianDist 中位數梯度

1 tumor : PairwiseMedianDist 最低。

2 normal : 中位數位於中間。

3 mixed : 目前中位數最高。

合理推論

1 tumor 可能因癌症趨同而甲基更相似（距離較小）

2 normal 原本有 haplotype 差異（距離中等）

3 mixed 的差異更大：組織來源（癌組織 vs 血液）差異可能超過 haplotype 效應

這條線現在還不是 **closeout** 結論。

這頁要怎麼講

1 這條線目前只到初步觀察，尚未完成全基因組與純樣本校正驗證。

2 策略：先完成純樣本分析，再回來分析 mixed 並加入適當校正與去噪。

3 在 deck 中應放在主線後段的一頁 hypothesis，不可拿來當主要證據頁。

下一步研究

Next Steps

研究主線已清楚：先純樣本、先 annotation，再決定是否有任何規則值得升級成核心流程。

下一步要做

- 1 繼續 brute-force caller + 甲基組合，累積 cross-dataset 比較矩陣
- 2 完成更多純樣本驗證（COLO829、H1437 等），補齊 big7_disk 路徑
- 3 把 Quality_Score、PairwiseMedianDist 接回 annotation / dashboard 輸出
- 4 混合樣本校正在純樣本驗證穩定後再做，不提前成為主線

現在不該做

- 1 不把 Quality 或 Pairwise 直接改成 hard keep 規則
- 2 不把 5kHz 單一 dataset 的特徵方向寫成跨樣本結論
- 3 不把 mixed sample 觀察提前成主要論點
- 4 不混用 $gq \geq 10$ 與 $qual \geq 10$ or $gq \geq 20$ 兩條不同規則

原則：先把 **annotation** 解決可解釋性與追蹤性，再考慮是否值得改核心 **hard keep / hard filter**。

附錄與可複查路徑

Appendix and Traceability

這份 draft deck 的來源報告、生成腳本、config、profile 與輸出資料夾都能直接回查。

核心文件

主整合報告

20260312_AI 自動化 F1 研究主線與 PPT 藍圖整合報告_01.md

研究主線週報

20260311_研究主線週報_20260305_20260311_phase2_annotation 整合_01.md

Pool B FN closeout

20260312_PoolB_FN_integration_closeout_01.md

設定與資料

四象限甲基 rescue 整合

20260311_HCC1395_四象限甲基 rescue 整合報告_01.md

PPT profile JSON

20260311_liao_research_ppt_profile_01.json

PPTX config JSON

20260312_ai_f1_research_pptx_config_01.json

版本與重生

Deck

20260312_AI 自動化 F1 研究主線與 PPT 藍圖整合報告_oral_v01.pptx

Version JSON

20260312_AI 自動化 F1 研究主線與 PPT 藍圖整合報告_oral_v01.version.json

Rerun

```
python build_ai_f1_research_pptx.py
--config
20260312_ai_f1_research_pptx_config_01.json
--output-pptx 20260312_AI 自動化 F1 研究主線與 PPT 藍圖整合報告_oral_v01.pptx
```

完整絕對路徑與完整指令已保留在 notes / version.json
狀態: draft · 版本: v01 · notes : embedded