

InterSubMod 研究主線整合週報

2026-03-05 至 2026-03-11，含 phase 2 與 annotation layer

**主結論已收斂為： caller-first、methylation-support、
annotation / QC / artifact triage 三層分工。**

來源週報： 20260311_研究主線週報_20260305_20260311_phase2_annotation 整合_01.md

本頁導讀

四象限資料： 5kHz / DORADO ×
paired / TO

phase 2： paired raw pileup/full
對照已完成

annotation layer 已正式接回分析
輸出層

產出時間： 2026-03-11
輸出模式： 研究內部混合版

本週重點結論

先看四條證據鏈，快速掌握可直接沿用的研究口徑



paired pure 已完成正式定稿級 rerun

HCC1395 5kHz paired 上，InterSubMod F1 由 LongPhase-S 0.8522 再推到 0.8532；DORADO paired 則幾乎持平略負，證明 5kHz 的確是較 noisy 的主實驗樣本。



TO candidate-specific rescue 已正式成立

HCC1395 5kHz TO 與 HCC1395 DORADO TO 都支持相同高層結論：caller-first 穩定成立；甲基特徵不是全負效果，但在同一 caller gate 後仍只作 support。



phase 2 已排除 raw paired 直上最終輸出的方向

paired raw pileup / full model 確實有更多召回，但 precision 成本太高。paired 場景目前仍應以 merged caller + LongPhase + InterSubMod 作為正式口徑。



annotation layer 已可制度化輸出

Quality_Score 適合升級成 support annotation，PairwiseMedianDist 適合升級成 dataset-aware support annotation，hp_assign_rate 應降階為 phase/QC annotation。

背景、問題與四象限

這一週的所有結果都用同一套三層框架與四象限資料集解讀

三層分工

第一層：caller-first

先用 GQ / QUAL / candidate-eligible 定義可救回的邊緣集合。

第二層：methylation-support

Pairwise、agreement 等甲基與標籤訊號補強排序。

第三層：annotation / QC / artifact

read-aware support、phase completeness 與 artifact triage 制度化輸出。

核心問題：哪些 caller 邊緣位點值得救回、哪些位點更像 artifact 或 dataset-specific 偏差。

資料四象限與可比性

HCC1395 5kHz paired

第一主實驗。最 noisy，但 paired 條件最完整，適合做規則壓力測試。

HCC1395 DORADO paired

第一交叉驗證。用同樣本不同平台檢查規則可攜性。

HCC1395 5kHz TO

最能看見 methylation-support 的 TO 場景，目前 support 成立但仍低於最佳 caller-only。

HCC1395 DORADO TO

TO 跨平台驗證已補齊。高層結論與 5kHz TO 一致，但 Pairwise 方向不同。

注意：5kHz TO 的 snapshot 來自 full tagged BAM；DORADO TO 目前是 candidate-window subset tagged BAM，因此 read-level 圖只能做方向比較，不能做跨 dataset 絕對值硬比。

主要目標與完成度

這一週的主線任務已從實驗探索推進到制度化與 annotation 層落地

主目標	子目標	完成度	本週結論
paired pure 正式重跑	5kHz / DORADO 新版欄位 rerun	100%	5kHz 有正增益；DORADO 幾乎持平略負。
TO 主流程打通	ClairS-TO → LongPhase-TO → InterSubMod	100%	5kHz TO pilot 已可重跑，LongPhase-TO phase 不改變 call set，本輪增益主要來自後段甲基過濾。
candidate-specific rescue	5kHz TO、DORADO paired、DORADO TO	100%	TO 下甲基 support 成立，但沒有穩定超過最佳 caller-only。
phase 2 benchmark / feature	raw pileup/full、finer interval、orthogonality	100%	paired raw 不適合直接取代 merged caller；Pairwise 明顯 dataset-dependent。
annotation layer 回接	把 phase 2 結果制度化輸出	100%	Quality / Pairwise 可升級成 annotation；hp_assign 降為 QC。
文件與流程制度化	週報、Agent、Skills、PPTX 工作流	100%	週報與簡報已可重複生成。

研究方向已收斂
從大量試規則，推進到明確分層與制度化輸出。

跨平台驗證已具雛形
5kHz 與 DORADO 已形成 paired / TO 對照矩陣。

下一步應先做 **annotation** 輸出
現階段先接報告、排序與診斷層，不急著改核心 hard rule。

研究推進時間軸

依日期整理本週主線進展與收斂節點

03-05

三路對照與全樣本規則 拆解

確認 mixed purity 容易混入組織差異，主線改成純樣本優先。

03-07

paired rerun 與 TO pilot

paired pure 與 TO 主流程正式跑通，確立 5kHz 主實驗樣本地位。

03-08~09

candidate-specific rescue

甲基 support 在 TO 下成立，但不穩定跨樣本。

03-11


phase 2 + annotation

paired raw 對照與 finer interval 已回接 annotation layer。

時間軸重點：3/05 先排除 mixed 主線，3/07 跑通 paired / TO，3/08~09 確立 candidate-specific rescue，3/11 完成 phase 2 與 annotation 回接。

paired pure 正式 rerun

5kHz 仍是最有壓力的主樣本； DORADO 則是穩定交叉驗證基準



圖意：X 軸是 paired dataset，Y 軸是 F1。每組三根柱分別代表 ClairS、LongPhase-S、InterSubMod。

5kHz paired

ClairS 0.8443 → LongPhase-S 0.8522 → InterSubMod 0.8532

意義：在最 noisy 主樣本上，甲基與 phase 整合有實際正增益。

DORADO paired

ClairS 0.8565 → LongPhase-S 0.8592 → InterSubMod 0.8590

意義：跨平台方向可驗證，但同一規則不保證可攜。

tumor-only candidate-specific rescue

TO 下已正式證明：甲基訊號不是全負效果，但仍未超過最佳 caller-only gate

HCC1395 5kHz TO

規則	TP	FP	$\Delta F1$
QUAL $\geq$ 10 or GQ $\geq$ 20	491	118	+0.006824
GQ $\geq$ 10 + Pairwise $\geq$ 0.20	300	68	+0.004219
GQ $\geq$ 10 + agreement_positive	148	25	+0.002163

甲基不是全負效果，而且確實救回一批 TP；但在同一 caller gate 後，仍未超過最佳 caller-only。

定位：caller-first + methylation-support

HCC1395 DORADO TO


規則	TP	FP	$\Delta F1$
GQ $\geq$ 10	40	11	+0.000540
Quality $\geq$ 60	208	77	+0.002620
Pairwise $\leq$ 0.20	173	60	+0.002217

DORADO TO 也證明甲基不是全負效果，但 Pairwise 方向與 5kHz TO 不同，顯示 support 具有 dataset-dependence。

定位：support 成立，但仍不可升級成全域規則

phase 2 : paired raw pileup / full 對照

paired 問題下，raw caller 有 recall 空間，但 precision 代價過高，不適合直接當最終輸出



圖意：X 軸為 F1，Y 軸為不同 caller 層級來源。左圖是 5kHz paired，右圖是 DORADO paired。

phase 2 結論

5kHz paired：raw pileup/full 確實多召回，但 precision 成本太高，F1 明顯低於 merged output。

DORADO paired：raw full 比 raw pileup 更高，但仍低於 merged output，更低於 LongPhase-S / InterSubMod。

paired 問題下，raw caller 不適合直接取代 merged caller 當正式輸出。

phase 2 的價值在於辨識『召回空間在哪裡』，不是直接把 raw caller 當最終口徑。

paired 的正式主線仍應維持 merged caller → LongPhase → InterSubMod

特徵定位與意義

這一週已把主要特徵從『到處試規則』收斂成可制度化的角色分工

GQ

caller-first 主規則

意義：目前最穩定、跨 dataset 最一致的 rescue 訊號。

限制：不能直接解讀成 ClairS / ClairS-TO 一開始就應全域放寬。

Quality_Score

support annotation

意義：在兩個 TO dataset 都呈正向 support，適合排序與解讀。

限制：高 Quality 的 FP 仍存在，不應直接 hard keep。

PairwiseMedianDist

dataset-aware support annotation

意義：5kHz TO 偏高 pairwise；DORADO paired / TO 偏低 pairwise。

限制：方向具樣本依賴，不能升級成全域規則。

agreement_positive

label-support

意義：在 5kHz TO 比單純 Strong/Subclone 更乾淨。

限制：尚未證明跨樣本穩定。

hp_assign_rate

phase / QC annotation

意義：反映 HP 可分派性與 phase completeness。

限制：TP 與 FP 都可能很高，不能當 truth-level keep 規則。

low VAF + high AD + low CV

artifact triage

意義：對 5kHz 的後段刪 FP 有價值。

限制：不適合作 TP rescue 主規則，也不能直接前置化。

annotation layer 決策

phase 2 的 finer interval 已回接到 annotation 層，但目前仍不應直接改成 hard keep / hard filter

HCC1395 5kHz TO

caller_primary_only (gq>=10)

$\Delta F1$ vs baseline : +0.006754

annotation 有資訊，但沒有超過最佳 caller-first。

HCC1395 DORADO paired

caller_strict_only (gq>=20)

$\Delta F1$ vs baseline : +0.000635

更嚴格的 caller gate 最穩。

Quality_Score

升級為 support annotation

HCC1395 5kHz paired

caller_primary_only (gq>=15)

$\Delta F1$ vs baseline : +0.000873

paired 仍由 caller 主導。

HCC1395 DORADO TO

caller_primary_only (gq>=10)

$\Delta F1$ vs baseline : +0.000540

annotation 追得很近，但仍略低於 caller-only。

PairwiseMedianDist

升級為 dataset-aware support annotation

hp_assign_rate

降階為 phase / QC annotation

目前最合理的下一步，是把 annotation 接到 round summary / dashboard / diagnostics 匯出，而不是先把它們改成新的 hard keep 或 hard filter。

待補齊事項與下一步

現在最合理的做法是先把 annotation 接到輸出層，再決定是否改核心規則

目前尚缺

paired 的 candidate-specific methylation coverage ceiling 仍偏低，paired 的甲基無效不能直接解釋成 paired 一定沒有價值。

TO 的 pileup vs full model 目前還沒有完整雙模型可比矩陣，因此 TO 模型差異結論仍以 pileup 路線為主。

5kHz TO 與 DORADO TO 的 snapshot scope 不同，read-level 圖只能做方向比較。

下一步

把 annotation 欄位接到 round summary、dashboard 與 diagnostics 匯出。

持續累積 finer interval 與 orthogonality 的 cross-dataset 證據。

若未來要升級規則，先升級成 annotation export，不直接改核心過濾。

保留 5kHz artifact triage 作 dataset-specific 診斷，而不是全域規則。

現階段不建議

不要把 Quality 或 Pairwise 直接變成新的 hard keep。

不要把 artifact-veto 直接拿去做 TP rescue 主規則。

不要把 5kHz 單一 dataset 的 Pairwise 方向寫成跨樣本結論。

複查路徑與再生成方式

本簡報對應的來源、數據與客製化設定檔都可直接回查與重生

核心文件

主週報

```
//big8_disk/liaoyoyo2001/InterSubMod/docs  
reports/validated/2026/03  
20260311_研究主線週報_20260305_20260311_phase2_annotation 整合_01.md
```

phase 2 報告

```
//big8_disk/liaoyoyo2001/InterSubMod/docs  
experiments/in_progress/2026/03  
20260311_phase2_paired_raw 與 feature_interval_orthogonality 分析_01.md
```

annotation 報告

```
//big8_disk/liaoyoyo2001/InterSubMod/docs  
experiments/in_progress/2026/03  
20260311_phase2_finer_interval 回接 annotation_layer 驗證_01.md
```

數據與重生指令

paired raw benchmark TSV

```
//big8_disk/liaoyoyo2001  
InterSubMod_runs/output  
big8_disk_output/research_rounds
```

annotation best policy TSV

```
//big8_disk/liaoyoyo2001  
InterSubMod_runs/output  
big8_disk_output/research_rounds
```

rerun command

```
//big8_disk/liaoyoyo2001/InterSubMod/scripts  
analysis/build_weekly_report_pptx.py --config  
big8_disk/liaoyoyo2001/InterSubMod/docs
```