

# InterSubMod 研究主線整合週報

## Weekly Research Review

2026-03-05 至 2026-03-11，含 phase 2 與 annotation layer

**主結論已收斂為：caller-first、methylation-support、annotation / QC / artifact triage 三層分工。**

報告整理時間 | 2026-03-11

Report Date

報告人 | 廖子游

Presenter

### Caller-first

GQ / QUAL / eligibility

### Methylation-support

Quality / Pairwise / agreement

### Annotation / QC / triage

dataset-aware + phase completeness

### Study Matrix

5kHz  
paired

DORADO  
paired

5kHz  
TO

DORADO  
TO

### Goal

Keep caller as the primary gate,  
use methylation for support and annotation.

# 報告大綱

## Agenda

本次簡報共 14 頁，分成 6 個主題，先架構後證據再下一步。

01

### 破題結論與主架構

Opening thesis and framework

02

### 資料四象限與研究推進

Study matrix and weekly milestones

03

### paired / TO 核心結果

Paired and tumor-only results

04

### 特徵定位與 phase 2

Feature roles and phase-2 benchmark

05

### annotation 決策

Annotation-layer decisions

06

### 缺口、下一步與複查路徑

Gaps, actions, and traceability

頁數策略：一頁一重點；若觀眾需要更多細節，附錄與原始報告可直接回查。

# 本週最重要的結論

## Opening Thesis

研究主線已從『大量試規則』收斂成固定分工：caller-first、methylation-support、annotation/QC/artifact。

目前最穩的救援仍在 **caller** 端；甲基訊號已證明有價值，但定位應是 **support**、**annotation** 與 **triage**，而不是直接取代 **caller**。

The stable pattern is caller-first. Methylation already shows value, but its current role is support, annotation, and artifact triage.

**5kHz paired**

**F1 +0.0010**

83 個 FP 被額外移除

**5kHz TO**

**caller-only 最佳**

甲基 support 成立但未超過 gate

**DORADO TO | support 非全負，但 Pairwise 方向與 5kHz 相反。**

**第一層 | caller-first**

用 GQ / QUAL / eligibility 定義可救回的邊緣集合。

**第二層 | methylation-support**

用 Quality / Pairwise / agreement 補強排序與支持。

**第三層 | annotation / QC / triage**

把 phase completeness、dataset-aware 訊號與 artifact 旁路制度化輸出。

# 資料四象限與比較邊界

Study matrix and comparability

四個 dataset 都已跑通，但 snapshot scope 與 candidate-specific coverage 不完全相同，解讀邊界必須分清楚。

## 四象限資料

### HCC1395 5kHz paired

最 noisy 的主實驗 paired 樣本

### HCC1395 DORADO paired

跨平台 paired 交叉驗證

### HCC1395 5kHz TO

最能看見 methylation-support 的 TO 場景

### HCC1395 DORADO TO

TO 跨平台驗證；本輪用 subset haplotag

## 比較時一定要記住

5kHz TO snapshot 來自 full tagged BAM；DORADO TO 來自 candidate-window subset tagged BAM。

paired candidate-specific coverage 只有 8%~20%，TO 則是 71%~100%。

因此 paired 的甲基無效不能直接解讀成 paired 沒有甲基價值。

PairwiseMedianDist 方向在 5kHz TO 與 DORADO TO 相反，只能做 dataset-aware 解讀。

**結論：四象限可以一起看，但不是所有數值都能硬做跨 dataset 絕對值比較。**

# 本週推進順序

## Weekly milestones

先排除 mixed 主線，再跑通 paired / TO、candidate-specific rescue、phase 2 與 annotation 回接。

03-05

### 三路對照與全樣本規則拆解

確認 mixed purity 容易混入組織差異，主線改成純樣本優先。

03-07

### paired rerun 與 TO pilot

paired pure 與 TO 主流程正式跑通，確立 5kHz 主實驗樣本地位。

03-08

### candidate-specific rescue

甲基 support 在 TO 下成立，但不穩定跨樣本。

03-11

### phase 2 + annotation


paired raw 對照與 finer interval 已回接 annotation layer。

**重要收斂：**這週不是只多做了幾條規則，而是把『什麼應進主流程、什麼只該留在分析層』這件事正式定型。

# paired pure 正式 rerun

## Paired benchmark

5kHz 是最有壓力的主樣本； DORADO 是跨平台交叉驗證基準。



圖表解讀 | X 軸: paired dataset ; Y 軸: F1。每組柱狀依序代表 ClairS、LongPhase-S、InterSubMod。

### 5kHz paired

**0.8522 → 0.8532**

增益主要來自額外移除 83 個 FP，不是大量救回 TP。

### DORADO paired

**0.8592 → 0.8590**

方向可對照，但同一條規則不保證可攜。

### paired 高層判讀


**caller-first 仍主導**

InterSubMod 在 paired 有價值，但目前更像精修 precision 的分析層。

# tumor-only rescue : caller 先、甲基後

## Tumor-only rescue

TO 下甲基特徵不是全負效果，但目前仍沒有穩定超過最佳 caller gate。



圖表解讀 | Y 軸為相對 baseline 的  $\Delta F1$ 。左圖是 5kHz TO，右圖是 DORADO TO。

## 5kHz TO

caller-only 最佳：`QUAL>=10 or GQ>=20`，`491 TP / 118 FP`。

`Pairwise>=0.20` 與 `agreement\_positive` 都有 support 價值，但仍低於最佳 caller-only。

結論：適合 `caller-first + methylation-support`。

## DORADO TO

`GQ>=10` 仍是最佳 caller-only。

`Quality>=60`、`Pairwise<=0.20` 單獨都為正值，但在 gate 後仍只作 support。

本輪使用 `candidate-window subset BAM + subset haplotag`，方向可判讀但不做絕對值硬比。

結論：甲基 support 成立，但目前最穩的主規則仍是 caller-first。

# 特徵分工重新定型

## Feature architecture

這週已把特徵從『候選規則』重新整理成三種用途：主規則、support、annotation/QC/triage。

### 主規則

caller-first

GQ

QUAL

candidate eligibility

最穩、跨 dataset 最一致，負責決定第一層可救回集合。

### 第二層支持

methylation-support

Quality\_Score

PairwiseMedianDist

agreement\_positive

在 TO 可提供額外 support，但方向可能依 dataset 改變。

### 註記與旁路

annotation / QC / triage

hp\_assign\_rate

artifact\_lowvaf\_highad\_lowcv

dataset-aware flags

不直接做 keep/filter；負責解讀、QC 與 artifact 診斷。

現階段最重要的不是再堆更多條件，而是把有訊息量但不夠穩定的特徵，明確放到正確層級。



# 關鍵特徵：哪些可升級、哪些不能

## Feature roles

看的是『目前最合理的定位』，不是單一 dataset 一時有效就直接升級成全域規則。

### GQ

#### caller-first 主規則

意義：目前最穩定、跨 dataset 最一致的 rescue 訊號。

限制：不能直接解讀成 ClairS / ClairS-TO 一開始就應全域放寬；它更像 caller-side threshold / ranking 訊號。

### Quality\_Score

#### support annotation

意義：在兩個 TO dataset 都呈正向 support，適合排序與解讀。

限制：高 Quality 的 FP 仍存在，不應直接 hard keep。

### PairwiseMedianDist

#### dataset-aware support annotation

意義：5kHz TO 偏高 pairwise；DORADO paired / TO 偏低 pairwise。

限制：方向具樣本依賴，不能升級成全域規則；目前更像 dataset-specific 結構 / noise proxy。

### agreement\_positive

#### label-support

意義：在 5kHz TO 比單純 Strong/Subclone 更乾淨。

限制：尚未證明跨樣本穩定。

### hp\_assign\_rate

#### phase / QC annotation

意義：反映 HP 可分派性與 phase completeness。

限制：TP 與 FP 都可能很高，不能當 truth-level keep 規則。

### low VAF + high AD + low CV

#### artifact triage

意義：對 5kHz 的後段刪 FP 有價值。


限制：不適合作 TP rescue 主規則，也不能直接前置化。

# phase 2 : raw caller 的邊界

## Paired raw benchmark

paired raw pileup / full model 有額外召回，但 precision 代價太大，不能直接取代 merged caller。

Paired raw caller benchmarks



圖表解讀 | 每個 panel 都是 paired 場景；X 軸為 F1，Y 軸為 caller 層級來源。

## 這頁要傳達的重點

5kHz paired : raw pileup / full 都比 merged 更高召回，但 precision 崩得更快。

DORADO paired : raw full 優於 raw pileup，但仍低於 merged output。

paired 問題下，raw caller 更適合拿來理解 recall 空間，不適合直接當最終輸出。


正式主線仍應維持

**merged caller → LongPhase → InterSubMod**

# annotation layer：目前該做的整合層

## Annotation-layer decision

phase 2 的 finer interval 已足夠回接 annotation，但還不到改 hard keep / hard filter 的時候。



圖表解讀 | 顯示四個 dataset 在目前最佳 policy 下，相對 baseline 的  $\Delta F1$ 。

## Quality\_Score

升級為 support annotation，適合排序、報告與人工審閱。

## PairwiseMedianDist

升級為 dataset-aware support annotation，不可直接寫成跨樣本全域規則。

## hp\_assign\_rate

明確降階為 phase / QC annotation；反映相位完整度，不直接做 truth keep。

# 還沒完成的邊界與風險

Open gaps and caveats

這頁要交代的是：哪些結論已可定稿、哪些仍需保守解讀。

## coverage 天花板

coverage ceiling

paired 的 candidate-specific coverage 只有 8%~20%，因此 paired 的甲基無效不能直接解讀成完全沒有價值。

## 模型缺口

model gap

TO 的 pileup vs full model 尚未補齊雙模型直接對照，因此 TO 模型差異目前只以 pileup 路線為主。

## 解讀限制

scope caveat

5kHz TO 與 DORADO TO 的 snapshot scope 不同，read-level 圖只能做方向比較；Pool B FN 仍有 caller-side rescue 空間。

這些邊界不代表研究失敗，而是記錄現階段不能講太滿的地方，以確保結論可靠。

# 下一步與現在不該做的事

## Next actions

接下來應優先把 annotation 接到輸出層，而不是急著改核心 hard filter。

1

把 annotation 接到 round summary / dashboard / diagnostics

2

繼續累積 finer interval 與 orthogonality 的 cross-dataset 證據

3

若要升級規則，先升級成 annotation export，不直接改核心過濾

4

保留 5kHz artifact triage 作 dataset-specific 診斷

## 現在不該做

不要把 Quality 或 Pairwise 直接變成新的 hard keep。

不要把 artifact-veto 直接拿去做 TP rescue 主規則。

不要把 5kHz 單一 dataset 的 Pairwise 方向寫成跨樣本結論。

原則：先用 **annotation** 解決可解釋性，再考慮是否值得改核心決策。

# 複查路徑與再生成方式

## Traceability and rerun

這份 deck 的來源、版本與重生設定都已獨立整理，方便之後重跑或換版。

### 核心文件

#### 主週報

/big8\_disk/liaoyoyo2001/  
InterSubMod/docs/reports/validated  
/2026/03/20260311\_研究主線週報\_20260305\_  
20260311\_phase2\_annotation 整合\_01.md

#### phase 2 報告

/big8\_disk/liaoyoyo2001/  
InterSubMod/docs/experiments/in\_  
progress/2026/03/20260311\_phase2\_  
paired\_raw 與 feature\_interval\_  
orthogonality 分析\_01.md

#### annotation 報告

/big8\_disk/liaoyoyo2001/  
InterSubMod/docs/experiments/in\_  
progress/2026/03/20260311\_phase2\_  
finer\_interval 回接 annotation\_layer 驗證  
\_01.md

### 主要數據

#### paired raw benchmark

**TSV**  
/big8\_disk/liaoyoyo2001/  
InterSubMod\_runs/output/big8\_  
\_disk\_output/research\_rounds  
/20260311\_phase2\_paired\_  
model\_feature\_analysis/  
paired\_raw\_model...

#### annotation best policy

**TSV**  
/big8\_disk/liaoyoyo2001/  
InterSubMod\_runs/output/big8\_  
\_disk\_output/research\_rounds  
/20260311\_phase2\_annotation\_  
layer/annotation\_best\_  
policy.tsv

### 版本與重生

#### version json

20260311\_研究主線週報  
\_20260305\_20260311\_phase2\_annotation 整合  
\_oral\_v03.version.json

#### deck path

20260311\_研究主線週報  
\_20260305\_20260311\_phase2\_annotation 整合  
\_oral\_v03.pptx

#### rerun

```
python build_weekly_report_pptx_oral_v2.py  
--config  
20260311_weekly_report_pptx_oral_config_01.json  
--profile 20260311_liao_research_ppt_profile_01.json
```

完整絕對路徑仍保留在主週報、設定檔與  
version.json；本頁優先保證可口頭說明與快速複查。